

Sistema de Detección de Patrones y Clasificación de Pacientes con Diabetes

Documentación técnica del análisis realizado en el notebook

Universidad Tecnológica de Panamá (UTP)
Facultad de Ingeniería de Sistemas Computacionales
Licenciatura en Ingeniería de Software · Grupo 1IL-132

Autor: Michael
Dataset: BRFSS 2015 — Diabetes Health Indicators

1. Introducción y objetivo

Un sistema de salud necesita analizar automáticamente miles de registros de pacientes para detectar patrones relacionados con la diabetes. Este documento describe, paso a paso, el desarrollo de un sistema computacional que procesa los datos, identifica inconsistencias, analiza los factores clínicos asociados a la enfermedad, genera un sistema de puntuación (score) de riesgo y clasifica pacientes nuevos.

Restricción de diseño: todo el sistema se construyó utilizando únicamente reglas y métodos estadísticos (pruebas de Chi-cuadrado, Odds Ratio, regresión logística y lineal, percentiles). No se utilizó ningún modelo de machine learning de caja negra (SVM, Random Forest, redes neuronales, etc.).

1.1 Dataset utilizado

Fuente: BRFSS 2015 (Behavioral Risk Factor Surveillance System). Archivo *diabetes_012_health_indicators_BRFSS2015.csv*, con 253,680 registros y 22 variables. La variable objetivo *Diabetes_012* toma 3 valores: 0 = sin diabetes, 1 = prediabetes, 2 = diabetes. Para el análisis de riesgo se trabajó con una versión binarizada (*target*): 0 = sin diabetes, 1 = prediabetes o diabetes.

2. Exploración inicial de los datos

Antes de cualquier análisis se revisó la forma general del dataset: distribución de la variable objetivo, de las variables numéricas más relevantes y las correlaciones entre todas las variables.

2.1 Distribución de la variable objetivo




Figura 1. El dataset está fuertemente desbalanceado: 84.2% de los pacientes no tiene diabetes, 13.9% tiene diabetes y solo 1.8% está en etapa de prediabetes. Este desbalance es clave para interpretar los resultados del modelo predictivo (Sección 6).

2.2 Distribución del Índice de Masa Corporal (BMI)




Figura 2. La media de BMI es 28.4, con una distribución sesgada a la derecha: existen pacientes con valores extremos (hasta 98) que luego se identifican como outliers en la Sección 3.

2.3 Distribución por grupo de edad




Figura 3. Categorías BRFSS de edad (1 = 18-24 años ... 13 = 80+ años). La muestra se concentra en las categorías 7 a 10 (aproximadamente 45 a 69 años).

2.4 Matriz de correlación




Figura 4. Las variables con mayor correlación con Diabetes_012 son GenHlth (0.30), HighBP (0.27), BMI (0.22) y DiffWalk (0.22). Income y Education correlacionan negativamente.

3. Detección de inconsistencias (basada en reglas)

Se aplicaron reglas de validación sobre los datos originales antes de cualquier análisis estadístico:

Regla aplicada	Resultado
Valores fuera de rango válido (BMI, edad, educación, ingreso, etc.)	0 violaciones
Outliers de BMI (rango intercuartílico, IQR)	9,847 registros (3.88%)
Registros duplicados exactos	23,899 registros (9.42%)
Inconsistencia lógica: CholCheck=0 pero HighChol=1	1,981 registros




Figura 5. Comparación visual de las tres inconsistencias más relevantes detectadas por reglas.

4. Análisis estadístico de factores clínicos

Para cada factor clínico binario se calculó la prueba de Chi-cuadrado (¿existe asociación con la diabetes?) y el Odds Ratio (¿cuánto multiplica el riesgo?), usando tablas de contingencia contra la variable *target*.

Factor	Chi-cuadrado	p-valor	Odds Ratio
HighBP	18,537.6	< 0.001	4.78
HighChol	11,217.0	< 0.001	3.24
DiffWalk	12,518.2	< 0.001	3.70
HeartDiseaseorAttack	7,939.9	< 0.001	3.51
Stroke	2,784.7	< 0.001	2.97

Smoker	999.4	< 0.001	1.41
PhysActivity	3,737.4	< 0.001	0.50
HvyAlcoholConsump	814.4	< 0.001	0.41




Figura 6. Odds Ratio de cada factor. Verde = protector ($OR < 1$), rojo = de riesgo ($OR > 1$). Todos los factores fueron estadísticamente significativos ($p < 0.001$).

Lectura: HighBP y HighChol son los factores que más multiplican el riesgo. PhysActivity y HvyAlcoholConsump aparecen como protectores en esta muestra ($OR < 1$), un resultado que se discute más a fondo en el notebook.

5. Sistema de puntuación (regresión logística → reglas)

Se utilizó la regresión logística únicamente como herramienta estadística para estimar el peso (coeficiente Beta) de cada factor. Estos coeficientes se convirtieron en una tabla de puntos interpretable, con una escala fija de 1 punto = 0.15 unidades de log-odds (equivalente a un Odds Ratio de aproximadamente 1.16 por punto). El clasificador final es la tabla de puntos, no la regresión en sí.

Variable	Coeficiente Beta	Puntos
HighBP	0.752	+5
HighChol	0.598	+4
GenHlth (por nivel, 1-5)	0.518	+3.5 por nivel
HeartDiseaseorAttack	0.238	+2
DiffWalk	0.082	+1
Stroke	0.124	+1
Age (por categoría, 1-13)	0.130	+0.9 por categoría
BMI (por unidad)	0.062	+0.4 por unidad
HvyAlcoholConsump	-0.697	-5

Smoker y *PhysActivity* se excluyeron de la tabla final: aunque estadísticamente significativos, su efecto era demasiado pequeño para aportar puntos perceptibles a esta escala (exclusión por parsimonia).




Figura 7. Puntos asignados a cada factor. Azul = suma riesgo, verde = resta riesgo.




Figura 8. Distribución del score calculado para los 253,680 pacientes, con los umbrales de clasificación (percentil 33 y percentil 66) marcados.

6. Clasificación de pacientes por umbrales estadísticos

Los pacientes se agruparon en tres categorías según su score, usando los percentiles 33 y 66 de la distribución (P33 = 27, P66 = 35) como reglas de corte:

Categoría	Rango de score	Tasa real de diabetes/prediabetes
Bajo riesgo	< 27	1.8%
Riesgo moderado	27 - 35	9.3%
Alto riesgo	> 35	32.7%




Figura 9. Validación del sistema de puntos: la tasa real de diabetes/prediabetes crece de forma monótona entre categorías, confirmando que el score separa correctamente a los pacientes.

7. Regresión lineal vs. regresión logística

Como alternativa, se estimaron los mismos pesos con una regresión lineal (Modelo Lineal de Probabilidad). Ambos métodos son igual de "estadísticos", pero la regresión lineal no está acotada entre 0 y 1, lo que puede generar probabilidades inválidas.




Figura 10. El 15.48% de las predicciones de la regresión lineal resultan negativas (probabilidades imposibles), mientras que solo el 0.00% supera 1.




Figura 11. El orden de importancia relativa de los factores es casi idéntico entre ambos modelos (normalizado para comparar forma, no escala).

Conclusión: se optó por la regresión logística para el sistema final: mismo poder explicativo que la lineal, sin el problema de generar probabilidades fuera de rango.

8. Modelo predictivo: clasificación de pacientes nuevos

Se entrenó la regresión logística como modelo predictivo real, dividiendo los datos en entrenamiento (80%, 202,944 filas) y prueba (20%, 50,736 filas). El modelo se evaluó sobre datos que nunca vio durante el entrenamiento.




Figura 12. Curva ROC del modelo (AUC = 0.813), con los umbrales de decisión 0.5 y 0.3 marcados sobre la curva.

Umbral de decisión	Accuracy	Sensibilidad	Especificidad
0.5	84.8%	18.2%	97.2%
0.3	82.2%	46.9%	88.9%




Figura 13. Matrices de confusión comparando ambos umbrales sobre el conjunto de prueba.

Hallazgo clave: con el umbral estándar de 0.5, el 84.8% de accuracy es engañoso: como solo el 15.8% de los pacientes tiene diabetes/prediabetes, el modelo puede acertar mucho prediciendo casi siempre "sano", dejando pasar al 82% de los casos reales (sensibilidad de solo 18.2%). Bajar el umbral a 0.3 sube la sensibilidad a 46.9%, a costa de más falsos positivos. La elección del umbral es una regla estadística justificada mediante la curva ROC, no un ajuste arbitrario ni un modelo de caja negra.

9. Conclusiones

1. El dataset presenta inconsistencias medibles (9.42% de duplicados, 3.88% de outliers de BMI, 1,981 contradicciones lógicas) que deben limpiarse antes de cualquier análisis.
2. Todos los factores clínicos evaluados están asociados significativamente con la diabetes ($p < 0.001$); HighBP y HighChol son los de mayor impacto ($OR > 3$).
3. El sistema de puntuación basado en los coeficientes de la regresión logística separa correctamente a los pacientes: la tasa real de diabetes/prediabetes crece de 1.8% a 32.7% entre las categorías de riesgo.
4. La regresión logística es preferible a la lineal para este problema: mismo poder explicativo, sin el 15.48% de probabilidades inválidas que genera la lineal.
5. El modelo predictivo alcanza un AUC de 0.813, pero el desbalance de clases (84.2% sin diabetes) exige ajustar el umbral de decisión para priorizar la sensibilidad, un criterio especialmente relevante en un sistema de salud.
6. Todo el sistema —desde la detección de inconsistencias hasta la clasificación final— se construyó exclusivamente con reglas y métodos estadísticos, sin recurrir a modelos de machine learning de caja negra.

10. Referencias

Dataset: BRFSS 2015 — Diabetes Health Indicators Dataset. Disponible en:
<https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset>